

《基于轮椅转弯问题的多模态大模型 空间建模能力的认知边界研究》

小组成员：王一帆，侯景祺，孙启哲，马悦鑫，石稷

日期：2026 年 6 月 19 日

目录

摘要	4
1 研究背景	4
2 任务场景与参考答案.....	5
3 研究问题与实验假设.....	6
4 数据集与实验矩阵.....	7
4.1 主实验 prompt 层级	7
4.2 补充控制实验设计	8
5 数据采集、预处理与标注流程.....	8
6 数据挖掘方法	9
6.1 数据预处理与特征构造。	9
6.2 描述性统计	10
6.3 关联规则.....	10
6.4 卡方检验与 Cramér's V	10
6.5 决策树.....	11
6.6 一致性挖掘与逻辑坍塌识别.....	12
6.7 配对消融、McNemar 检验、视觉显著性控制和聚类 bootstrap.....	12
6.8 噪声敏感度分析	14
6.9 净空边界曲线与逻辑坍塌、认知边界.....	14
6.10 高级综合挖掘：从单因素解释走向多变量证据	15
6.11 题目中的要求与建议与本项目使用的方法的对应关系	17
7 主实验结果	18
8 模式挖掘结果	20
9 图片消融	23

10 尺寸补充效应 24

11 无关环境描述梯度..... 26

12 净空裕量边界 27

13 视觉显著性控制..... 28

14 外部泛化 30

15 实验整体挖掘 31

16 高级综合挖掘：让算法自己验证哪些变量重要..... 32

17 各模型的认知边界定义..... 39

18 主要结论与数据挖掘证据来源对照..... 41

19 实验意义 43

20 面向实际使用的建议..... 43

21 局限性与后续工作..... 44

22 复现路径与代码说明..... 44

23 结论 45

参考文献 46

摘要

本研究从一个很具体的场景出发：楼梯转角平台里，电动轮椅到底能不能通过。问题看起来只是判断能或不能，但模型需要同时处理照片、尺寸文字、管道和消防栓的位置、井道、非规则墙面边界、红圈标出的通行区域、轮椅尺寸，以及只能直线运动，转弯时停下调转方向的运动限制。本文不想简单给模型排个名，而是想把错误拆开看：模型在哪些输入条件下最容易把可通过误判为不可通过，图片、尺寸和路径提示分别改变了什么，空间认知边界能不能被量化到厘米级。

项目最后整理出 2196 个分析行次，覆盖主实验、图片消融、尺寸补充、八场景外部泛化和三组补充控制实验。主实验 270 条复核样本中，总体正确率为 25.2%，pass 率为 25.2%，blocked 率为 67.4%，unsupported assumption 失败模式占 59.3%。图片消融给出的证据最强：去掉原始照片后，blocked 率从 72.9% 降到 38.2%，text-only minus image = -34.7 pp，聚类 95% CI [-44.4 pp, -25.3 pp]， $q=0.00015$ 。补充管道和消防栓尺寸后，正确率只变化 +1.7 pp，说明问题不是少给了几个数字那么简单。净空裕量实验又把边界往前推了一步：ChatGPT 和 Qwen 的 pass 判断 50% 交点约为 0.20 cm，Gemini 约为 1.12 cm，Claude 约为 4.25 cm。不同模型对厘米级余量的反应差别很大。

我们认为这组实验最值得看的地方在于：模型主要不是输在读不到尺寸，而是输在没能把局部障碍、可通行区域、运动约束和净空裕量合成一个稳定的空间状态。照片按理说应该提供更多现场信息，可在这个任务里，它反而放大了管道和消防栓这类显眼物体的干扰，使模型更容易保守地说 blocked。无障碍通行、老年人出行、残疾人辅助决策和建筑现场安全判断，都不能只看 AI 回答得是否详细，还要追问它是否真的围绕关键空间约束在推理。

关键词：空间建模；认知边界；多模态大模型；轮椅通行；数据挖掘；视觉幻觉；无障碍环境

1 研究背景

现在很多人已经习惯把现实问题丢给大模型：拍一张照片，问这个东西放得进去吗？这条路能走吗？这里有没有安全隐患？。这类问题很日常，但并不简单。模型必须把图像、语言、尺寸和行动方式放到同一个空间关系里判断。如果它只盯着照片里最显眼的物体，或者把一个局部障碍直接理解成整条路被堵住，答案就会看起来谨慎，实际上却可能是错的。

使用轮椅转弯场景来测试人工智能的空间建模能力认知边界，对数据挖掘这门课程来说，它适合设计成实验矩阵：采集模型回复后，可以标注结构化字段，再用关联规则、卡方检验、决策树、配对消融和边界曲线挖掘规律。对现实来说，轮椅能不能通过不是抽象数学题，它关系到残疾人和老年人的出行安全。AI 如果以后参与无障碍环境评估，就必须知道自己在哪些条件下不可靠。一个错误的不能通过可能让人放弃可行路线；一个错误的可以通过也可能带来风险。

所以这份报告没有把 AI 当成黑箱打分对象，而是把它当作一个需要审计的辅助决策系统。我们关心的是推理有没有抓住关键空间事实，会不会被无关环境细节或显眼障碍带偏，在边界条件下能不能保持一致。

2 任务场景与参考答案

老师给出的核心场景是一处楼梯转角平台。照片中能看到墙角、地面、楼梯扶手、靠墙管道、消防栓箱、井道或检修口等设施。管道和消防栓尤其显眼，很容易让人直觉上觉得这里被挡住了。题目示意图用红圈标出了实际可通行位置，补充尺寸也说明，关键通行区域的净空没有被这些设施完全占掉。参考答案是：在给定尺寸和运动约束下，轮椅可以通过。



图 1 真实楼梯转角照片。该图是多模态模型实际收到的视觉输入之一。




图 2 尺寸示意图。该图用于实验设计、人工核对和报告解释，未作为图片输入发送给待测模型。

难点主要有四个。第一，空间边界不是标准矩形，不能直接套用普通房间或走廊的经验。第二，障碍物只是局部障碍，不能把有管道和消防栓直接等同于整条路径被封死。第三，轮椅不是自由旋转，题目限定只能直线运动，转弯时需要停下调向，所以判断更接近分段路径可行性。第四，照片和文字可能给出不同方向的暗示：照片强化障碍物的存在，文字给出关键尺寸。可靠的模型要能把两者放到一起，而不是被某一个局部线索带走。

3 研究问题与实验假设

本报告主要回答这些问题。

RQ1：在真实楼梯转角题中，大模型总体是更接近正确判断，还是更偏向过度乐观或过度保守？

RQ2：描述越详细、越形式化，模型是否一定更准确？

RQ3：真实照片到底是在帮助模型理解空间，还是会因为显著障碍物造成干扰？

RQ4：补充管道和消防栓尺寸后，错误是否明显减少？

RQ5：无关环境描述、视觉显著性和净空裕量分别如何影响模型判断？

RQ6：能否为不同模型定义在哪些精度和输入条件下容易发生逻辑坍塌的认知边界？

对应的初始假设有三条。H1：真实照片会增加信息量，但也可能强化局部障碍物，所以多模态输入不一定优于纯文字。H2：更完整的尺寸描述如果没有清楚组织路径，可能只会让回答更像在建模，不一定提高正确率。H3：认知边界可以用净空裕量梯度刻画。随着有效净空从负裕量变到正裕量，模型的 pass 率、blocked 率和重复稳定性会出现各自的转折点。

4 数据集与实验矩阵

本报告使用 5 组分析数据表，共 2196 个分析行次。这里的分析行次不是互相独立样本的简单总和，因为主实验样本会在图片消融和尺寸版本比较中被复用。为了避免口径混乱，后文不计算混合总体正确率，而是让每个实验使用自己的估计量。

实验数据	行数	模型数	题目/匹配单元	数据构成	主要用途
主实验	270	8	15	同一真实楼梯转角场景；包含照片、尺寸、轮椅运动约束和不同描述层级。	总体边界、层级效应、模型差异、失败模式。
图片消融	450	5	225 对	同一模型、同一 prompt、同一重复序号下比较有图和无图。	估计真实照片本身是否诱发过度 blocked。
尺寸补充效应	300	5	60 个匹配 cell	比较未写入管道/消防栓尺寸的旧题面与写入新尺寸后的新题面。	判断错误是否主要来自信息缺失。
八场景外部泛化	336	3	56	更早的八类空间问题，含 pass、blocked、borderline、unknown 参考类型。	检验模型是否在一般空间题上也同样失效。
补充控制实验	840	5	56	无关环境描述梯度、净空裕量边界、视觉显著性控制。	把干扰机制和厘米级认知边界拆出来。

4.1 主实验 prompt 层级

主实验不是把同一个问题机械重复很多次，而是围绕同一场景构造阶梯式 prompt，用来观察信息组织方式改变后，模型的空间建模会怎么变。L1 接近日常提问，L2S 强调路径和局部净空，L2 给出更完整的尺寸，L3 要求坐标或碰撞检查式建模。

层级	信息组织方式	它能检验什么	可能诱发的错误
L1	照片加基本题意、轮椅运动限制和少量核心尺寸。	检验模型在接近普通用户提问时的直觉判断。	模型可能依赖照片中最显眼的障碍物，忽略局部可通行区域。
L2S	用自然语言强调可通行路径、局部净空和停下调向的过程。	检验模型是否能把问题理解为分段路径可行性。	如果路径提示过强，可能相当于把答案方向告诉模型，因此需要与其他层级比较。
L2	提供完整尺寸、障碍尺寸、有效净空、轮椅尺寸和比较要求。	检验模型能否整合数值条件。	细节变多后，模型可能在局部障碍上做无依据外推。

层级	信息组织方式	它能检验什么	可能诱发的错误
L3	要求坐标、状态空间或碰撞检查式推理。	检验形式化空间建模能力。	模型可能生成看似严谨的公式或坐标，但关键边界设错。

4.2 补充控制实验设计

补充实验是在主实验和第一轮分析之后设计的，目的不是单纯扩大样本量，而是把已经出现的现象拆成可以检验的机制。比如，主实验发现照片可能造成干扰，就设计图片消融和视觉显著性控制；发现模型容易被管道和消防栓吓到，就设计尺寸补充和净空边界；发现题面细节可能有影响，就设计无关环境描述梯度。

补充实验	规模	自变量	控制方式	要回答的问题
无关环境描述梯度	5 prompt 变体 × 4 噪声水平 × 5 模型 × 3 次 = 300	环境外观细节约 0%、5%、10%、20%	自然加入墙面、灰尘、柜体、照明等描述，不告诉模型这些信息无关。	冗余环境信息是否降低正确率或增加 unsupported assumption。
净空裕量边界	3 prompt 变体 × 7 净空裕量 × 5 模型 × 3 次 = 315	有效净空相对轮椅宽度为 -10、-5、-2、0、+2、+5、+10 cm	只改变文字中的关键净空数值。	模型在何种厘米级裕量下从 blocked 转向 pass，何处发生不稳定。
视觉显著性控制	5 prompt 变体 × 3 视觉条件 × 5 模型 × 3 次 = 225	原始照片、照片+尺寸护栏、纯文字场景描述	尽量只改变视觉证据或其解释护栏。	照片中的显著障碍物是否造成过度 blocked。

5 数据采集、预处理与标注流程

数据采集使用 `src/collect_responses.py`。每条记录保存模型名称、`prompt_id`、`repeat_index`、输入模态、图片路径、原始回复、`finish_reason` 和原始 JSON。这样后续不仅能看最终判断，还能追踪网络错误、长度截断、无回答等异常。

预处理流程包括四步。

原始采集：按模型配置和 `prompt` 矩阵调用 API 或读取本地模型结果。

补采与合并：对网络失败、长度截断、缺失模型单元进行 `retry`，再通过合并脚本去重。

机器初标：使用性能更强的 LLM 对回复进行结构化标注，生成 `final_judgment`、`failure_mode` 等字段。

复核：优先复核低置信度、无明确结论、判断与参考答案冲突、机器标注自相矛盾的样本。

标注字段分三类。结果字段包括 `final_judgment`、`is_correct` 和 `failure_mode`。过程字段包括 `reasoning_step_count`、`uses_formula`、`uses_coordinate_system` 和 `spatial_modeling_depth`。实验元数据包括 `level`、`input_modality`、`prompt_variant`、`noise_level_percent`、`clearance_margin_cm`、`visual_condition` 等。

需要说明的是，`noise_level_percent`、`clearance_margin_cm`、`visual_condition` 这些字段只是实验记录，不是发给待测模型看的标签。无关环境描述实验不会告诉模型这些信息无关；净空边界实验也不会告诉模型本实验只改变关键净空。这样处理更接近真实使用场景。

6 数据挖掘方法

老师强调过，数据挖掘不能只是人拿着数据讲故事。所以我们把模型回复转成结构化数据后，用多种方法从不同角度找规律。它们不是互相替代的工具，而是在回答不同层次的问题。




图 3 总体分析流程图

6.1 数据预处理与特征构造。

所有分析脚本都以复核后的 CSV 为入口，使用 `utf-8-sig` 读取并保留原始字段。`src/mine_patterns.py` 和 `src/advanced_mining.py` 会把自然语言标注字段转成可计算特征，例如把 `is_correct` 转为 `correct_label` 或 `correct_num`，把 `final_judgment` 转成 `pass`、`blocked`、`uncertain`、`no_answer` 四类判断，把 `failure_mode=unsupported_assumption` 转成二值指标。同时，脚本会派生

model_family、model_origin、response_length_bin、reasoning_bin、spatial_depth_label、noise_level_bin、clearance_margin_bin 等字段。也就是说，后续挖掘不是直接读模型原文，而是基于“模型-题目-prompt-模态-标注结果-派生特征”的结构化行为表。

6.2 描述性统计

描述性统计回答发生了什么。比如主实验正确率是多少、blocked 率是多少，不同层级和模型各自表现如何。它不能证明因果，但能避免只凭几个印象深的例子下结论。本项目中，src/analyze_results.py 会生成按模型、层级、模态和失败模式聚合的 CSV 与图。

src/analyze_results.py 和 src/mine_patterns.py 都使用分组聚合实现基础统计。做法是按 model_key、level、input_modality、perturbation_type、failure_mode 等字段 groupby，然后对二值变量取均值：is_correct 的均值就是正确率，final_judgment == blocked 的均值就是 blocked 率，uses_formula 的均值就是公式使用率。对正确率，脚本只在 is_correct 明确为 0 或 1 的样本上计算；unknown、borderline 或不可评价样本不进入正确率分母，但仍可进入覆盖率、判断分布和失效模式统计。

6.3 关联规则

关联规则用来回答哪些条件组合经常导向某种结果。核心指标是 support、confidence 和 lift。support 表示规则覆盖多少样本，confidence 表示前件出现时后件出现的比例，lift 表示这个比例相对后件总体出现率放大了多少。例如，level=L2S AND perturbation_type=none -> correct 的 confidence 很高、lift 大于 1，就说明 L2S 且无扰动时，正确判断比总体更常见。

公 式 为 ： $\text{support}(X \rightarrow Y) = \text{count}(X \cap Y) / N$ ； $\text{confidence}(X \rightarrow Y) = \text{count}(X \cap Y) / \text{count}(X)$ ； $\text{lift} = \text{confidence}(X \rightarrow Y) / \text{support}(Y)$ 。

src/mine_patterns.py 没有调用 mlxtend 或 FP-Growth 库，而是使用可解释的组合枚举实现。脚本先把每行样本转成特征项集合，例如 model_family=gpt、level=L2S、input_modality=vision、clearance_margin_bin=margin_plus_2cm；再把目标项限定为 final_judgment、correct_label、failure_mode、judgment_flip 等结果。随后枚举 1 到 max_antecedent_size 个特征项组成的前件，统计前件计数、目标计数和联合计数，筛选 support >= min_support 且 confidence >= min_confidence 的规则，并输出 support、confidence、lift、leverage 和 conviction。也就是说，本项目的关联规则是“穷举小规模前件 + 阈值筛选”的实现，适合当前字段数和样本量，重点是解释性而不是追求大规模频繁项集挖掘效率。

6.4 卡方检验与 Cramér's V

卡方检验判断两个类别变量是否独立，Cramér's V 衡量关系强度。p 值告诉我们这种关系是否可能来自随机波动，Cramér's V 则告诉我们关系有多强。课程报告里，Cramér's V 比单独看 p 值更有用，因为样本量一大，很小的差异也可能显著，但未必有解释价值。

Cramér's V 的计算为： $V = \sqrt{\chi^2 / (n \cdot \min(r-1, c-1))}$ 。V 越接近 1，关系越强；越接近 0，关系越弱。

src/mine_patterns.py 对多个维度和目标变量构造列联表，例如 level × correct_label、model_key × failure_mode、perturbation_type × final_judgment。脚本按列联表计算期望频数，再累加 $(\text{observed} - \text{expected})^2 / \text{expected}$ 得到 χ^2 ；p 值由 scipy.stats.chi2.sf 计算。Cramér's V 使用 $\sqrt{\chi^2 / (n \cdot \min(r-1, c-1))}$ 标准化，因此可以比较不同大小列联表的关联强弱。报告中优先解释 Cramér's V，是因为它比 p 值更能体现实际关系强度。

6.5 决策树

决策树回答的是：如果让算法自己找区分正确和错误的条件，它会先看什么。本项目使用浅层可解释决策树，不追求最高预测准确率，而是把多变量关系压成一组可读分支。比如先看是否为 L2S，再看是否有某类扰动，再看模型类别。如果决策树把 level、perturbation_type、model_key 排在前面，这些变量就值得重点解释。

src/mine_patterns.py 的决策树目标是 correct_label，只使用明确 correct 或 incorrect 的样本。所有类别特征先被展开成 one-hot 二值特征，例如 level=L2S、model_family=qwen、visual_condition=original_photo。模型使用 sklearn.tree.DecisionTreeClassifier(max_depth=3, min_samples_leaf=5, random_state=42)，因此它是一棵刻意限制深度的可解释浅层树，而不是追求最高预测性能的复杂树。脚本输出训练准确率、可用时输出分层交叉验证准确率，并用 export_text 导出规则文本。




图 4 关联规则与浅层决策树流程图

6.6 一致性挖掘与逻辑坍塌识别

一致性挖掘回答的是：同一模型在同一空间条件下是否会反复给出同样判断。它和正确率不同，关注的是判断是否稳定；一个模型即使偶尔答对，如果三次重复在 pass、blocked、uncertain 之间摇摆，仍说明它在这个条件附近没有稳定的空间表示。

主实验中的一致性由 src/analyze_results.py 计算，分组单位是 model_key + scenario_id，统计同一模型在同一场景下的 final_judgment 唯一值个数和多数判断占比 majority_share。补充实验中的一致性由 src/analyze_supplementary_experiments.py 计算，分组单位扩展为 supplement_experiment + model_key + prompt_variant + 条件值，例如噪声比例、净空裕量或视觉条件。脚本还计算判断熵 judgment_entropy_bits。如果同一条件下出现多个判断，且多数占比低于 0.7 或熵大于等于 1.0，就标记为 logical_collapse=1。因此，本项目的一致性挖掘本质上是重复采样条件下的多数稳定性和信息熵分析。

6.7 配对消融、McNemar 检验、视觉显著性控制和聚类 bootstrap

图片消融和尺寸补充不能只比较两个总体平均值，因为不同模型、prompt 和重复次数会带来混杂。因此我们尽量在同一模型、同一 prompt、同一重复序号上配对比较。图片消融中，每个有图回复都有对应的无图回复。McNemar 检验适合比较配对二分类结果是否出现方向性变化；聚类 bootstrap 以模型-prompt 单元为重采样单位，用来估计效应区间。

结果解读时这样看：如果 text-only minus image 的 blocked 率差异为负，说明去掉图片后 blocked 变少；如果置信区间不跨 0，方向就比较稳。

对图片消融、McNemar 检验来说，src/analyze_image_ablation.py 先用 source_prompt_id/prompt_id + model_key + repeat_index 构造配对键，保证每个有图回答和无图回答来自同一模型、同一题目和同一次重复。McNemar 检验只看正确性是否在配对中发生方向性变化：有图错而无图对记为 improved，有图对而无图错记为 worsened。脚本使用精确二项式形式计算双侧 p 值，并对多个 scope 的检验做 Benjamini-Hochberg q 值校正。这个实现适合回答“去掉图片后，判断是否出现系统性方向变化”。

视觉显著性控制是图片消融的进一步细化。src/analyze_supplementary_experiments.py 筛选 supplement_experiment=visual_salience，按 visual_condition 汇总指标，并以 original_photo 为基线，把 photo_dimension_guardrail 和 text_only_scene_description 与原图条件配对比较。配对单位仍是 model_key + prompt_variant + repeat_index，指标包括 correct、pass、blocked 和 unsupported assumption。这个实现用于分离“照片本身带来的视觉干扰”和“文字尺寸信息不足”两个问题。

对于 bootstrap 和聚类 bootstrap，图片消融、尺寸补充和补充实验中的置信区间都不是用正态近似硬套公式，而是用重采样。普通 bootstrap 是对配对差值或单元差值有放回抽样，重复计算均值后取 2.5% 和 97.5% 分位数。图片消融还增加了模型-prompt 聚类 bootstrap：先把同一 prompt_id + model_key 下的重复回答差值平均成一个单元，再对这些单元重采样，避免同一模型或同一 prompt 的重复样本被当成完全独立观测。尺寸补充效应也采用单元层面对比，因为旧版本每个单元 2 条回答、新版本每个单元 3 条回答，不能简单当作逐行一一配对。




图 5 配对检验与 bootstrap 流程图

6.8 噪声敏感度分析

噪声敏感度分析回答的是：无关环境描述比例增加时，模型是否更容易变得保守，或更容易提出没有尺寸依据的障碍假设。它在实验矩阵中控制无关环境描述比例，再从模型输出中估计正确率、blocked 率和 unsupported assumption 率的变化趋势。

src/analyze_supplementary_experiments.py 先筛选 supplement_experiment=noise 的样本，按 model_key + noise_level_percent 汇总正确率、blocked 率和 unsupported assumption 率。随后对每个模型、每个指标用 np.polyfit(x, y, deg=1) 拟合线性斜率，并把斜率换算为“每增加 5% 无关环境描述”的变化量，即 slope_per_5_percent_noise。同时，脚本用 model_key + prompt_variant + repeat_index 作为配对单位，把 5%、10%、20% 噪声条件分别和 0% 基线相减，并用 bootstrap 给出差异区间。因此，报告中的噪声敏感度不是主观观察，而是由梯度斜率和配对差异共同支撑。

6.9 净空边界曲线与逻辑坍塌、认知边界

净空裕量实验把参考答案从一个固定场景扩展成一条边界曲线。有效净空小于轮椅宽度时，参考答案应为 blocked；有效净空大于轮椅宽度时，参考答案应为 pass；0 cm 是边界点，不直接纳入正确率。模型 pass 率随净空裕量变化，可以定义 pass 50% 交点。交点越大，模型越保守；交点越小，模型越早倾向 pass。

在净空边界实验中，逻辑坍塌是 6.6 一致性挖掘的具体应用。逻辑坍塌关注重复稳定性，如果同一模型、同一 prompt、同一净空条件下三次回答出现明显分裂，比如 pass、blocked、uncertain 混在一起，就说明模型在这个条件附近没有稳定内部表示。这里用 majority_share 和 judgment_entropy_bits 记录这种不稳定。

src/analyze_supplementary_experiments.py 筛选 supplement_experiment=boundary_precision，按 model_key + clearance_margin_cm 汇总 pass 率、blocked 率、正确率、多数占比和判断熵。threshold_crossing 函数会按净空裕量排序，在相邻两个裕量点之间用线性插值寻找 pass 率穿过 0.5 的位置，即 margin_50_pass_cm_interpolated。脚本还记录正裕量下正确率首次达到 0.67 的位置、负裕量下 blocked 率达到 0.67 的最近位置，以及出现逻辑坍塌的裕量点。这样，模型认知边界被定义为一组可计算阈值，而不只是“感觉它保守”。

6.10 高级综合挖掘：从单因素解释走向多变量证据

在基础挖掘之外，本项目把已复核的多版本数据和补充实验数据合并为 1815 行跨实验分析表。目标是把数据挖掘推进到四个更正式的层次。

第一，训练正则化逻辑回归模型预测 is_correct。输入特征包括数据集版本、模型、模型家族、输入模态、描述层级、扰动类型、prompt 变体、视觉条件、净空裕量类别、回复长度分箱、推理步数分箱和空间建模深度等。使用 class_weight=balanced 是为了避免正确/错误比例不均导致模型只学多数类。它不是为了部署预测器，而是用交叉验证衡量这些变量组合是否真的能解释正确性。

第二，获取原始变量置换重要性。做法是先在测试集上计算基线 balanced accuracy，然后随机打乱某一个原始变量，观察准确率下降多少。如果打乱 level 后性能明显下降，说明描述层级确实携带了可解释信息，而不是我们事后主观挑出来的因素。

具体实现中，一二两部分由 src/advanced_mining.py 实现，其把多版本复核数据和补充实验复核数据合并后，只取 is_correct 明确为 0/1 的样本训练预测模型。类别变量使用 OneHotEncoder(handle_unknown="ignore", min_frequency=3)，数值变量先用中位数填补缺失值，再 StandardScaler 标准化。分类器为 LogisticRegression(max_iter=5000, class_weight="balanced", C=0.5, solver="liblinear")，用分层 K 折交叉验证输出 accuracy、balanced accuracy 和 ROC-AUC。置换重要性不是打乱 one-hot 后的单个虚拟列，而是在测试集上打乱原始字段，如 level 或 dataset_group，

重复 20 次，观察 `balanced accuracy` 相对基线下降多少。因此它回答的是“哪个原始变量族对预测正确性最有贡献”。

第三，脚本构造模型行为指纹。每个模型被表示为一组行为指标：正确率、`pass` 率、`blocked` 率、`unsupported assumption` 率、公式使用率、坐标使用率、平均空间建模深度、回答长度、判断熵和过度保守指数。然后对这些行为向量做 PCA 和聚类，观察模型是否形成不同错误风格。

`src/advanced_mining.py` 先按 `model_key` 汇总每个模型的行为指纹，包括 `correct`、`pass`、`blocked`、`uncertain`、`no_answer`、`unsupported assumption`、公式使用率、坐标使用率、平均空间建模深度、平均推理步数、平均回答长度、判断熵、过度保守指数和诊断错误指数。然后对这些数值指标填补缺失、标准化，使用 PCA 降到二维，并用 `KMeans(n_clusters=min(3, 模型数), random_state=42)` 聚类。这里的聚类把模型按照“错误风格”分组，例如高度保守、公式化但不稳定、`unsupported assumption` 高等。

第四，脚本计算二阶交互效应。它比较两个条件同时出现时的结果率，与两个条件边际效应相加后的期望值之间的残差。这个指标可以发现“单看 A 或 B 不明显，但 A+B 一起出现时特别容易出错”的组合。需要注意的是，边界实验中存在正确率接近 100% 的天花板效应，因此交互残差应作为线索，而不是单独作为因果结论。

`src/advanced_mining.py` 对 `correct_rate`、`blocked_rate` 和 `unsupported_assumption_rate` 三个目标，枚举成对条件组合，例如 `model_family=claude + prompt_variant=path_margin`。对每个组合，脚本计算联合率 `joint_rate`，再用加性基线估计期望率： $\text{left_rate} + \text{right_rate} - \text{base_rate}$ 。由于比例不能小于 0 或大于 1，报告采用截断到 0-1 后的期望率计算 `interaction_residual_clipped`。只有样本数达到 `min_interaction_n` 的组合才保留。




图 6 高级综合挖掘流程图

6.11 题目中的要求与建议与本项目使用的方法的对应关系

本研究把老师在题目文档中提出的若干关键词落实为可复现的数据挖掘方案。第一，一致性挖掘对应 `model_prompt_consistency.csv`、`logical_collapse_by_condition.csv`、判断熵 `judgment_entropy_bits`、`majority_share` 和逻辑坍塌候选区间，目标是发现同一模型在同一空间条件下是否反复给出相同判断。第二，噪声敏感度分析对应无关环境描述梯度实验和 `noise_slope_by_model.csv`，目标是度量每增加 5% 环境描述时，正确率、`blocked` 率和 `unsupported assumption` 率如何变化。第三，模型认知边界聚类对应 `model_behavior_fingerprints.csv`、PCA 和 K-Means 聚类，目标是把模型从简单正确率排名转化为行为风格分组。第四，失效模式挖掘对应 `failure_mode_counts.csv`、失效模式关联规则和本次补充的失效模式热力图，目标是找出模型错误最常见的结构原因。

老师在题目里建议使用 FP-Growth 做关联规则挖掘。我们实现的方法和 FP-Growth 稍有区别，在代码层面实现的是支持度、置信度和 lift 的关联规则挖掘流程，目标和解释方式与 FP-Growth 方向一致。

7 主实验结果

主实验 270 条样本中，正确率为 25.2%，pass 率为 25.2%，blocked 率为 67.4%，uncertain 率为 7.4%。参考答案是 pass，所以大部分 blocked 都是过度保守错误。失败模式里，unsupported assumption 占 59.3%。也就是说，最常见的问题不是算错，而是在证据不足时直接假设障碍物封死了通行路径。

层级	样本数	正确率	blocked 率	unsupported 率	公式使用率	坐标使用率	平均建模深度
L1	72	29.2%	51.4%	44.4%	22.2%	4.2%	1.61
L2S	54	48.1%	46.3%	31.5%	46.3%	5.6%	1.67
L2	72	15.3%	81.9%	76.4%	94.4%	33.3%	2.22
L3	72	13.9%	84.7%	77.8%	93.1%	77.8%	2.62

表里最值得注意的是 L2S。它不是尺寸最多的层级，但正确率最高，因为它用自然语言把可通行路径和局部净空组织起来。相反，L2 和 L3 提供更多尺寸或要求形式化建模，正确率反而下降。这个结果说明，在这个任务里，正确的信息组织比数字堆叠更重要。




图 7 主实验各层级正确率与空间建模深度。读图时注意：柱或点越高表示正确率越高，深度线越高表示回复越形式化。

图 7 可以从两个方向读：先看不同层级的正确率，再看空间建模深度是否同步提高。L3 的建模深度最高，正确率却处在最低一档。这说明看起来更会建模不等于真的建模正确。评估 AI 回复时，步骤多、公式多、语气严谨，都不能直接当成可靠性的证据。

模型	样本数	正确率	pass 率	blocked 率	unsupported 率	平均深度
local_gemma4_26b_a4b_textonly	15	53.3%	53.3%	26.7%	53.3%	2.07
local_gemma4_12b_vision	15	46.7%	46.7%	53.3%	46.7%	2.00
yunwu_claude	45	44.4%	44.4%	48.9%	40.0%	2.09
yunwu_qwen	45	31.1%	31.1%	60.0%	53.3%	2.40
yunwu_doubao	45	22.2%	22.2%	71.1%	55.6%	1.82
local_gpt_oss_20b_textonly	15	20.0%	20.0%	40.0%	0.0%	0.07
yunwu_chatgpt	45	6.7%	6.7%	91.1%	88.9%	2.51
yunwu_gemini	45	6.7%	6.7%	93.3%	84.4%	2.13




图 8 各模型正确率与 blocked 率。读图时重点看正确率和 blocked 率是否反向变化。

图 8 显示，不同模型的错误形态差别很大。ChatGPT 和 Gemini 在主实验中的正确率都只有 6.7%，blocked 率超过 90%，几乎稳定地把这个场景判断为不可通过。Claude 的主实验正确率较高，但后面的边界实验显示，它在厘米级裕量上仍偏保守。本地小模型样本量较小，这里只作为探索性对照。

这一节的作用是给后续所有挖掘建立基线：模型在老师真实题上的主要错误不是随机答错，而是系统性地向 **blocked** 偏移。L2S 的表现又说明，模型不是完全不能处理这道题，而是对信息组织方式非常敏感。也就是说，正确率差异并不只是模型能力强弱造成的，还和 **prompt** 是否把“可通行路径、局部障碍、净空关系”组织成可推理结构有关。这个基线现象会在后面的关联规则、决策树、图片消融和边界实验中反复出现：当输入让模型看到显眼障碍或形式化维度堆叠时，模型更容易保守；当输入帮助它抓住路径结构时，正确性才会上升。

8 模式挖掘结果

只看总体正确率，很容易得到某模型更差这种粗结论。模式挖掘想追问的是：模型为什么错，哪些 **prompt** 结构更容易导向正确，哪些变量和失败模式绑得最紧。

前件	后件	支持计数	置信度	lift
level=L2S AND perturbation_type=none	correct_label=correct	15	83.3%	3.31
model_key=yunwu_gemini AND response_length_bin=medium_500_1499	correct_label=incorrect	33	100.0%	1.34
model_family=gemini_gemma AND model_origin=cloud_yunwu AND response_length_bin=medium_500_1499	correct_label=incorrect	33	100.0%	1.34
model_origin=cloud_yunwu AND reasoning_bin=steps_1_3 AND response_length_bin=medium_500_1499	correct_label=incorrect	31	100.0%	1.34
model_key=yunwu_gemini AND uses_formula=1	correct_label=incorrect	30	100.0%	1.34
model_family=gemini_gemma AND model_origin=cloud_yunwu AND uses_formula=1	correct_label=incorrect	30	100.0%	1.34
model_family=gpt AND uses_coordinate_system=1	correct_label=incorrect	27	100.0%	1.34
model_key=yunwu_chatgpt AND uses_coordinate_system=1	correct_label=incorrect	27	100.0%	1.34

关联规则的第一条强规则是 `level=L2S AND perturbation_type=none -> correct`，`confidence=83.3%`，`lift=3.31`。这说明，当 **prompt** 用自然语言清楚组织路径，并且没有额外扰动时，正确判断明显更常见。其他规则则显示，公式、坐标和特定模型组合经常与错误或 `unsupported assumption` 同时出现。




图 9 主实验关联规则。读图时看 confidence 和 lift：confidence 高表示规则内部稳定，lift 高表示相对总体有放大效应。

变量	目标	n	χ^2	Cramér's V	p
failure_mode	correct_label	270	179.01	0.814	0.0
failure_mode	final_judgment	270	307.31	0.754	0.0
perturbation_type	correct_label	270	42.38	0.396	1.4e-05
model_key	final_judgment	270	75.09	0.373	0.0
model_key	correct_label	270	36.48	0.368	6e-06
uses_formula	final_judgment	270	34.85	0.359	0.0
input_modality	final_judgment	270	30.84	0.338	0.0
perturbation_type	final_judgment	270	55.55	0.321	9.9e-05

卡方和 Cramér's V 显示，failure_mode 与正确性的关系最强，主实验中 $V=0.814$ 。这不是一句错因和正确性相关的废话，因为 failure_mode 不是直接复制正确性，而是对错误原因的结构化分类。它说明，只要抓住 unsupported assumption、概念混淆、计算错误等模式，就能解释大部分正确与错误的分化。perturbation_type、model_key 和 level 也有中等强度关联，prompt 组织方式和模型类型都不是随机因素。




图 10 主实验 Cramér's V。读图时越靠前、数值越大，说明该变量越能解释目标变量。

决策树特征	重要性
perturbation_type=semantic_path_decomposition	0.252
perturbation_type=motion_constraint_emphasis	0.225
level=L2S	0.183
model_key=yunwu_gemini	0.179
model_key=local_gemma4_26b_a4b_textonly	0.093
response_length_bin=medium_500_1499	0.063
reasoning_bin=steps_4_5	0.004

主实验决策树文本如下。用来检查算法自动选出的分裂条件，是否和前面的机制解释能对上。

```

Training accuracy: 0.8556
Stratified 5-fold CV accuracy: 0.8148 +/- 0.0166
Class legend: 0=incorrect, 1=correct

|--- level=L2S <= 0.50
| |--- perturbation_type=motion_constraint_emphasis <= 0.50
| | |--- model_key=local_gemma4_26b_a4b_textonly <= 0.50
| | | |--- class: 0
| | | |--- model_key=local_gemma4_26b_a4b_textonly > 0.50
| | | |--- class: 1
| |--- perturbation_type=motion_constraint_emphasis > 0.50
| |--- response_length_bin=medium_500_1499 <= 0.50

```

```

| | | |--- class: 1
| | | |--- response_length_bin=medium_500_1499 > 0.50
| | | |--- class: 0
|--- level=L2S > 0.50
| | |--- perturbation_type=semantic_path_decomposition <= 0.50
| | | |--- model_key=yunwu_gemini <= 0.50
| | | |--- class: 1
| | | |--- model_key=yunwu_gemini > 0.50
| | | |--- class: 0
| | |--- perturbation_type=semantic_path_decomposition > 0.50
| | | |--- reasoning_bin=steps_4_5 <= 0.50
| | | |--- class: 0
| | | |--- reasoning_bin=steps_4_5 > 0.50
| | | |--- class: 0

```

决策树给出的启发是：正确性首先由描述层级和扰动类型区分，而不是由回复长度直接决定。这和关联规则一致。换句话说，怎么组织空间关系比说了多少更关键。

模式挖掘回答了哪些变量自动浮现为关键解释因素。关联规则指出 L2S 且无扰动时正确判断明显放大，Cramér's V 指出失败模式、扰动类型、模型和层级与结果存在较强关联，决策树又把描述层级和扰动类型放在较靠前的分裂位置。三种方法的形式不同：关联规则看条件组合，Cramér's V 看变量与结果的关联强度，决策树看监督分类中的分裂路径；但它们共同指向同一个结论：模型错误不是由回答长短或单个案例偶然造成，而是与 prompt 结构、扰动条件和失败模式稳定相关。

9 图片消融

图片消融实验是本项目里最接近因果推断的一组实验。我们保留同一模型、同一 prompt、同一重复序号，只比较有图和无图两种条件。如果两组结果系统性不同，就可以比较有力地说明图片本身改变了模型判断。

指标	有图	无图	无图-有图	聚类 bootstrap 95% CI	q	解释
正确率	22.2%	31.1%	+8.9 pp	[-0.4 pp, +18.7 pp]	q=0.0682	方向上无图更好，但聚类区间略跨 0，作为趋势而不是强显著结论。
blocked 率	72.9%	38.2%	-34.7 pp	[-44.4 pp, -25.3 pp]	q=0.00015	强证据：去掉照片显著降低 blocked，说明照片诱发过度保守。
unsupported assumption 率	64.4%	54.7%	-9.8 pp	[-19.6 pp, +0.0 pp]	q=0.0682	方向上无图减少无依据假设，但区间接近 0。




图 11 图片消融效应。读图时重点看误差线是否跨 0；blocked 率的区间完全低于 0，说明去图后 blocked 稳定下降。

最强的结论来自 blocked 率：有图时为 72.9%，无图时为 38.2%，差异为 -34.7 pp。这不是说无图模型更聪明，而是说在这个场景中，原始照片把模型注意力拉向管道和消防栓这些显眼障碍，使它们更容易把局部障碍误扩展成整体不可通行。正确率也有 +8.9 pp 的提高趋势。

图片消融的配对设计让我们可以把差异更明确地归因到图片输入本身。同一模型、同一 prompt、同一重复序号下，无图条件 blocked 率显著下降，说明原始照片并没有稳定提供空间建模增益，反而把模型注意力推向管道、消防栓等显眼障碍。正确率的提升趋势区间略跨 0，所以不能过度声称无图一定更准确；但 blocked 率的稳定下降已经足以支持一个更稳健的结论：在这个具体空间任务中，视觉输入最强的影响是加重保守判断，而不是帮助模型完成几何推理。这一结论与后面的视觉显著性控制、外部泛化和认知边界热力图形成同一条证据链。

这也和老师分享的 Mirage 论文形成了参照。Mirage 论文指出，模型可能在没有图像时生成看似基于视觉的描述，从而制造视觉理解幻觉。本项目看到的是另一面：即使图像真实存在，模型也可能被显眼视觉线索牵着走，给出不可靠的空间判断。多模态输出里，看起来在看图和真的把视觉证据用于正确推理并不是一回事。

10 尺寸补充效应

第一轮结果里，模型经常被没有完整尺寸的管道和消防栓吓到。于是后续补充了更多尺寸数据，包括管道和消防栓结合体尺寸、红圈可通行区域等。直觉上，数字更多应该让模型更准确。但数据没有支持这个简单想法。

指标	旧题面	新题面	新旧	95% CI	q
正确率	15.0%	16.7%	+1.7 pp	[-5.0 pp, +8.9 pp]	q=0.8256
blocked 率	76.7%	77.8%	+1.1 pp	[-6.4 pp, +8.3 pp]	q=0.8256
unsupported assumption 率	60.8%	71.1%	+10.3 pp	[-0.3 pp, +20.8 pp]	q=0.1345
空间建模深度	2.17	2.30	0.12	[0.03, 0.23]	q=0.0756




图 12 尺寸补充效应。读图时注意正确率和 unsupported assumption 的方向：数字更多不等于判断更准。

正确率从 15.0% 到 16.7%，只增加 +1.7 pp， $q=0.8256$ 。空间建模深度从 2.17 到 2.30，提高 0.12。模型确实写得更像在建模了，但没有稳定做对。也就是说，补充尺寸提高了形式化程度，却没有解决局部空间关系组织的问题。

这组结果可以被看作对一种常见直觉的反证：如果模型错，是不是因为我们没有把尺寸告诉它？数据表明并非如此。补充障碍物尺寸后，模型更容易写出看似完整的空间分析，空间建模深度略有提高，但正确率几乎没有改善，unsupported assumption 也没有被稳定压低。换句话说，更多数字并没有自动转化为更好的空间表示。模型真正缺少的是把尺寸约束投射到可通行路径上的能力：哪些尺寸决定最窄净空，哪些障碍只是局部占位，轮椅直线运动和停下调向如何影响通过

性。这一结论与第 7 章 L3“更形式化但不更正确”的现象相互印证，也解释了为什么仅靠把 prompt 写得更长、更细，不能解决空间建模边界问题。

这对实际使用 AI 很有提醒意义。很多用户会以为，只要把尺寸都告诉模型，答案就会可靠。这个实验说明，在复杂空间问题中，尺寸只是原材料；模型还必须知道哪些尺寸构成关键约束，哪些障碍只是局部障碍，通行路径到底在哪里。缺少这一步，更多数字有时只是让模型更自信地犯错。

11 无关环境描述梯度

老师要求报告里包含基于统计的核心规律，比如增加无关环境描述后，模型表现是否下降。因此我们设计了 300 条无关环境描述梯度样本。

整体上，20% 环境描述相对 0% 时，正确率变化为 +4.0 pp, bootstrap 95% CI [-8.0 pp, +16.0 pp]; unsupported assumption 变化为 +6.7 pp, bootstrap 95% CI [-6.7 pp, +20.0 pp]。不过两个区间都跨 0，所以不能说无关文字环境描述显著降低了正确率。

模型	正确率斜率/每 5% 噪声	blocked 斜率/每 5% 噪声	unsupported 斜率/每 5% 噪声	正确率 20%-0%	unsupported 20%-0%
yunwu_chatgpt	+3.8 pp	-3.8 pp	-0.2 pp	+13.3 pp	+0.0 pp
yunwu_claude	-2.5 pp	+2.1 pp	+3.4 pp	-13.3 pp	+6.7 pp
yunwu_doubao	-0.0 pp	+1.0 pp	+2.3 pp	+0.0 pp	+13.3 pp
yunwu_gemini	+0.0 pp	-0.0 pp	-1.1 pp	+0.0 pp	-6.7 pp
yunwu_qwen	+4.2 pp	-1.3 pp	+4.6 pp	+20.0 pp	+20.0 pp




图 13 无关环境描述梯度曲线。读图时看曲线是否随噪声单调变化；本实验中整体趋势不够稳定。

这一节的价值在于区分两类干扰机制。若模型只是因为输入信息变多、文字变长而出错，那么无关环境描述比例增加时，正确率或 `unsupported assumption` 应该出现更稳定的恶化趋势。但 `bootstrap` 区间跨 0，整体趋势不稳定，说明文字层面的信息负荷并不是主导因素。这样，第 9 章图片消融中的 `blocked` 率大幅下降就不能简单解释为“少给信息所以少犯错”，而更应解释为真实照片中的视觉显著性把模型推向了局部障碍判断。负结果在这里不是失败，而是帮助我们排除了一个替代解释，使“视觉显著性干扰”这条机制链更加清楚。

12 净空裕量边界

模型不太会空间推理太笼统。为了让认知边界可测量，我们把关键最窄有效净空改造成梯度变量。当净空比轮椅宽度小 10、5、2 cm 时，参考答案应为 `blocked`；当净空比轮椅宽度大 2、5、10 cm 时，参考答案应为 `pass`；0 cm 是边界条件。

模型	pass 50%交点(cm)	稳定正确所需正裕量 (cm)	坍塌候选裕量(cm)	-2 cm pass 率	0 cm pass 率	+2 cm pass 率
yunwu_chatgpt	0.20	2.0	0.0	0.0%	44.4%	100.0%
yunwu_claude	4.25	未达到	2.0;5.0;10.0	0.0%	11.1%	33.3%
yunwu_doubao	-1.00	2.0	无	0.0%	100.0%	100.0%
yunwu_gemini	1.12	2.0	无	0.0%	0.0%	88.9%
yunwu_qwen	0.20	2.0	0.0	0.0%	44.4%	100.0%




图 14 净空裕量 pass 曲线。读图时看曲线从 0 到 1 的转折位置，越靠右说明模型越保守。

图和表把认知边界落到了具体数字上。ChatGPT 和 Qwen 的 pass 50% 交点约为 0.20 cm，它们在净空刚转正时开始倾向 pass，但 0 cm 附近仍不稳定。Gemini 的交点约为 1.12 cm，略保守。Claude 的交点约为 4.25 cm，需要明显正裕量才更愿意判断 pass，而且在 +2、+5、+10 cm 仍出现坍塌候选区间。Doubao 的交点为 -1.00 cm，在边界实验中较早倾向 pass，但主实验仍会被真实场景干扰。

所以，模型评估不能只看一个总正确率。一个模型可能主实验还可以，但在厘米级边界上保守；另一个模型可能在边界实验里反应灵活，却在真实照片中被显眼障碍带偏。认知边界应该由准确率、blocked 倾向、净空阈值和重复稳定性共同定义。

本节的实验意义在于“空间建模能力边界”转化成了可测量的阈值问题。pass50 交点表示模型从倾向 blocked 转向倾向 pass 的位置，交点越靠右，说明模型需要更大的正裕量才愿意承认可通过，也就是越保守。逻辑坍塌候选区间则表示模型在同一裕量条件下重复回答不稳定，说明它不仅判断偏保守，而且内部空间表示没有稳定下来。因此，厘米级边界不是单一正确率能替代的指标：一个模型可能总体正确率尚可，但在 +2 cm 或 +5 cm 这种关键安全裕量附近仍会摇摆；另一个模型可能更早 pass，却在真实照片中被显眼障碍带偏。这个实验让“认知边界”从描述性概念变成了可比较、可复现的数值指标。

13 视觉显著性控制

视觉显著性控制实验比较三种条件：原始照片、照片加尺寸护栏提示、纯文字场景描述。它的统计强度弱于 225 对主图片消融，但可以再检查一次：图片干扰是不是来自显眼障碍物。

相对原始照片，照片+尺寸护栏的正确率变化为 +8.0 pp，blocked 率变化为 -6.7 pp；纯文字场景描述的正确率变化为 +5.3 pp，blocked 率变化为 -9.3 pp。这些区间跨 0，所以只能作为方向性证据，不能写成强显著证据。

模型	原图 blocked	护栏 blocked	纯文字 blocked	原图正确率	护栏正确率	纯文字正确率
yunwu_chatgpt	86.7%	86.7%	86.7%	6.7%	13.3%	6.7%
yunwu_claude	73.3%	66.7%	46.7%	13.3%	26.7%	46.7%
yunwu_doubao	53.3%	33.3%	26.7%	46.7%	66.7%	46.7%
yunwu_gemini	100.0%	100.0%	100.0%	0.0%	0.0%	0.0%
yunwu_qwen	6.7%	0.0%	13.3%	26.7%	26.7%	20.0%




图 15 视觉显著性控制。读图时比较 original_photo 与另外两组的 blocked 率变化。

分模型看，Gemini 在三个视觉条件下几乎全部 blocked，说明它对这个场景的保守判断很稳定。Doubao 和 Claude 在护栏或纯文字条件下改善更明显。这也提醒我们，同一种 prompt 改写策略，对不同模型不一定有同样效果。

视觉显著性控制的统计强度弱于主图片消融，因此它不应被单独写成强显著结论。但它的方向很重要：无论是给照片加尺寸护栏，还是改成纯文字场景描述，blocked 率都相对原始照片下降。这说明第 9 章看到的图片干扰不是偶然来自某一批回答，而更可能与原始照片中障碍物的视觉突出程度有关。这个结果还提示，所谓“多模态能力”不能只看模型是否能描述图像元素，还要看它是否能把视觉元素放回任务相关的几何约束中。若模型看见障碍物后只扩大风险，而不能同时利用文字尺寸和路径描述判断可通行区域，那么视觉输入反而会成为认知边界的一部分。

14 外部泛化

如果模型在老师真实题中表现很差，可能有两种解释：一种是模型总体不会空间题；另一种是这个真实场景触发了某种特定失败机制。八场景外部泛化实验就是用来区分这两种解释的。

数据集	模型	总样本	可评价样本	正确率	unsupported 率	平均深度
老师真实题	yunwu_chatgpt	45	45	6.7%	88.9%	2.51
老师真实题	yunwu_gemini	45	45	6.7%	84.4%	2.13
八场景外部题	yunwu_chatgpt	112	60	90.0%	19.6%	2.57
八场景外部题	yunwu_gemini	112	60	96.7%	43.8%	2.52




图 16 共同模型跨任务正确率。读图时比较同一模型在老师题和八场景题中的落差。

结果很直接：ChatGPT 在老师真实题中正确率为 6.7%，但在八场景可评价样本中为 90.0%；Gemini 在老师题中为 6.7%，八场景中为 96.7%。这说明模型不是完全不会空间判断，而是在真实楼梯转角题中，被局部障碍、照片显著性、非规则空间和运动约束共同击穿了。

外部泛化实验的重要性在于排除一个过于简单的解释：模型是否只是总体空间能力差？八场景结果显示，同一批模型在更规则的空间题上可以取得较高正确率，因此老师真实楼梯题的 AI 解题低正确率不能被归结为“模型完全不会空间题”。真正困难的是这个场景同时包含真实照片、局部障碍、非规则边界、轮椅运动限制和厘米级净空判断。也就是说，模型的认知边界不是在所有

空间问题上均匀出现，而是在多个干扰条件叠加时被触发。这一点把外部泛化与前面的图片消融、尺寸补充和净空边界连接起来：模型不是没有空间知识，而是不稳定地把空间知识用于真实复杂场景。

15 实验整体挖掘

补充实验共 840 条，其中准确率可评价样本为 795 条。它们的作用是把主实验中看到的现象拆成更细的机制。

补充实验	样本数	正确	错误	不纳入准确率	正确率	blocked 率	unsupported 率
净空裕量边界	315	253	17	45	93.7%	54.6%	12.4%
无关环境描述 梯度	300	97	203	0	32.3%	51.0%	59.7%
视觉显著性控制	225	52	173	0	23.1%	58.7%	66.2%

变量	目标	n	χ^2	Cramér's V	p
prompt_variant	correct_label	795	365.63	0.678	0.0
failure_mode	correct_label	795	356.32	0.669	0.0
failure_mode	final_judgment	840	1040.43	0.642	0.0
experiment_group	correct_label	795	308.74	0.623	0.0
supplement_experiment	correct_label	795	308.74	0.623	0.0
perturbation_type	correct_label	795	308.74	0.623	0.0
boundary_reference_class	final_judgment	315	231.93	0.607	0.0
clearance_margin_bin	final_judgment	315	233.40	0.497	0.0
input_modality	correct_label	795	190.95	0.490	0.0
response_length_bin	final_judgment	840	207.77	0.352	0.0

补充实验中，prompt_variant 与正确性的 Cramér's V=0.678，experiment_group 与正确性的 V=0.623，input_modality 与正确性的 V=0.490。这些关系都不弱，说明补充实验不是简单凑样本，而是确实把不同机制区分开了。

补充实验决策树特征	重要性
experiment_group=cognitive_boundary	0.717
model_key=yunwu_doubao	0.102
prompt_variant=obstacle_locality	0.079

补充实验决策树特征	重要性
level=L2S	0.052
boundary_reference_class=positive_margin_pass	0.029
model_key=yunwu_claude	0.020
response_length_bin=short_80_499	0.001

补充实验决策树文本如下。

```

Training accuracy: 0.8377
Stratified 5-fold CV accuracy: 0.8189 +/- 0.0146
Class legend: 0=incorrect, 1=correct

|--- experiment_group=cognitive_boundary <= 0.50
|   |--- model_key=yunwu_doubao <= 0.50
|   |   |--- prompt_variant=obstacle_locality <= 0.50
|   |   |   |--- class: 0
|   |   |   |--- prompt_variant=obstacle_locality > 0.50
|   |   |   |--- class: 1
|   |   |--- model_key=yunwu_doubao > 0.50
|   |   |   |--- level=L2S <= 0.50
|   |   |   |   |--- class: 0
|   |   |   |   |--- level=L2S > 0.50
|   |   |   |   |--- class: 1
|   |--- experiment_group=cognitive_boundary > 0.50
|   |   |--- model_key=yunwu_claude <= 0.50
|   |   |   |--- response_length_bin=short_80_499 <= 0.50
|   |   |   |   |--- class: 1
|   |   |   |   |--- response_length_bin=short_80_499 > 0.50
|   |   |   |   |--- class: 1
|   |   |   |--- model_key=yunwu_claude > 0.50
|   |   |   |   |--- boundary_reference_class=positive_margin_pass <= 0.50
|   |   |   |   |   |--- class: 1
|   |   |   |   |   |--- boundary_reference_class=positive_margin_pass > 0.50
|   |   |   |   |   |--- class: 1

```

第 15 章的意义是把补充实验从“多跑了一些样本”提升为“机制变量确实可被数据挖掘区分”。Cramér's V 显示 prompt_variant、experiment_group 和 input_modality 与正确性都有不弱关联，说明不同补充实验确实改变了模型行为，而不是只增加了随机样本量。补充实验决策树进一步表明，experiment_group、model_key、prompt_variant 等变量会被算法自动选入分裂路径，这与前面的单项实验结论一致：图片、尺寸、噪声、边界和 prompt 组织方式分别对应不同的失败机制。换句话说，第 15 章是把第 9 到第 14 章的机制实验重新放回一个统一挖掘框架中，验证这些实验条件确实具有统计区分度。

16 高级综合挖掘：让算法自己验证哪些变量重要

本项目进一步把所有复核后的版本化数据和补充实验数据合并为跨实验分析表，共 1815 行，其中 1614 行可用于正确性建模。这个分析回答了一个更综合的问题：如果让算法同时看到模型、数据集、模态、层级、prompt 变体、推理过程等变量，它是否能稳定解释哪些回答会正确。

指标	均值	标准差	折数	样本数	正类比例
accuracy	0.810	0.014	5	1614	43.9%
balanced_accuracy	0.804	0.014	5	1614	43.9%
roc_auc	0.868	0.005	5	1614	43.9%

正则化逻辑回归的 5 折交叉验证 balanced accuracy 为 0.804，ROC-AUC 为 0.868。这说明正确性不是随机噪声，也不是只能靠人工挑案例解释；实验变量和回复行为变量合在一起，已经能较稳定地区分正确和错误回答。这里使用 balanced accuracy，是因为正确与错误样本比例并不完全均衡，普通 accuracy 可能高估多数类。

特征族	编码后特征数	最大绝对系数	平均绝对系数
perturbation	20	1.524	0.449
level	4	1.520	0.742
dataset	7	1.450	0.532
analysis	5	1.450	0.610
prompt	14	1.428	0.481
model	17	0.964	0.399
boundary	3	0.570	0.355
visual	4	0.561	0.351
input	2	0.514	0.478

特征族	编码后特征数	最大绝对系数	平均绝对系数
clearance	8	0.483	0.261

按逻辑回归系数聚合后，贡献最高的特征族包括 `perturbation`、`level`、`dataset`、`analysis`、`prompt` 和 `model`。这个结果与前文单因素挖掘互相印证：描述层级、实验条件和 `prompt` 组织方式不是旁枝末节，而是能被多变量模型自动选出的核心解释变量。

原始变量	基线 <code>balanced accuracy</code>	置换重要性	标准差
<code>level</code>	0.796	0.079	0.015
<code>dataset_group</code>	0.796	0.045	0.014
<code>analysis_tier</code>	0.796	0.031	0.009
<code>input_modality</code>	0.796	0.027	0.009
<code>prompt_variant</code>	0.796	0.018	0.008
<code>response_length_bin</code>	0.796	0.015	0.010
<code>perturbation_type</code>	0.796	0.014	0.006
<code>visual_condition</code>	0.796	0.009	0.006
<code>response_length_num</code>	0.796	0.009	0.009
<code>reasoning_step_count_num</code>	0.796	0.009	0.004

置换重要性的读法是：随机打乱某个变量后，模型性能下降越多，说明该变量越重要。在本项目中，`level`、`dataset_group`、`analysis_tier`、`input_modality` 和 `prompt_variant` 排在前列。这比只比较均值更有说服力，因为它是在多个变量同时存在时，检查每个变量对预测正确性的独立贡献。

模型	样 本 数	正 确 率	blocke d 率	pass 率	unsupporte d 率	过 度 保 守 指数	判 断 熵
yunwu_gemini	394	39.6%	78.2%	17.5%	64.5%	0.607	0.91
yunwu_chatgpt	394	43.5%	68.5%	22.1%	45.2%	0.464	1.21
yunwu_deepseek	112	56.7%	50.9%	18.8%	42.0%	0.321	1.77
local_gpt_oss_20b_textonly	27	18.5%	44.4%	18.5%	11.1%	0.259	1.50
yunwu_claude	282	40.3%	53.5%	29.8%	42.9%	0.238	1.46
local_gemma4_12b_vision	15	46.7%	53.3%	46.7%	46.7%	0.067	1.00
yunwu_doubao	282	53.1%	45.7%	45.0%	33.7%	0.007	1.35
yunwu_qwen	282	44.0%	30.9%	35.1%	46.5%	-0.043	1.79

模型行为指纹把模型从“准确率排名”转化为“错误风格画像”。例如 Gemini 的 blocked 率和过度保守指数最高，说明它最容易稳定地给出不能通过；ChatGPT 也高度保守，但 unsupported assumption 低于 Gemini；Qwen 的判断熵较高，说明它在不同条件下更不稳定。这种画像比单一正确率更适合定义认知边界，因为真实使用中我们关心的是模型会以什么方式失效。




图 17 模型行为指纹 PCA 聚类。读图时看模型是否聚成相似错误风格，而不是只比较横纵坐标绝对值。

图 18 不只展示某一个指标，而是把主实验正确率不足、主实验 blocked、照片显著性 blocked、噪声假设斜率和厘米级 pass50 阈值合并为模型-边界维度矩阵。颜色越深表示该模型在对应维度上越接近认知边界或逻辑坍塌。读图时应先横向看同一模型的脆弱维度，再纵向比较不同模型在哪类边界上更容易失效。




图 18 认知边界热力图。颜色表示标准化风险，单元格文字保留原始指标值。

图 19 把模型行为指纹转为雷达图。它同时比较正确性、不过度保守、少无依据假设、判断稳定、空间建模深度和公式/坐标使用。




图 19 模型对比雷达图。

高级综合挖掘的作用，是检查前面各章靠单因素和分组统计得到的结论，在多变量条件下是否仍然站得住。正则化逻辑回归的交叉验证结果说明，正确性不是无法解释的随机噪声；置换重要性把 level、dataset_group、analysis_tier、input_modality 和 prompt_variant 排在前列，说明描述层级、数据集版本、实验条件和输入模态确实携带独立解释信息。PCA 聚类 and 雷达图则把模型差异从单一正确率扩展到错误风格：有的模型高度保守，有的模型 unsupported assumption 更突出，有的模型判断熵更高。认知边界热力图进一步把这些风险压缩到同一张图中，使“模型认知边界”不再只是某一个指标，而是多种失效维度的组合。这样，第 16 章实际上是在用多变量方法回头验证第 7 到第 15 章的核心发现。

目标	条件 A	条件 B	样 本 数	联 合 率	截 断 加 性 期望	截 断 交 互 残差
blocked_rate	model_family=claude	boundary_reference_class=positive_margin_passe	27	48.1 %	7.9%	+40.3 pp
blocked_rate	prompt_variant=dimension_guardrail	spatial_depth_label=depth_3	20	25.0 %	65.2 %	-40.2 pp
unsupported_assumption_rate	dataset_group=teacher_olddims_v1	model_family=qwen	24	16.7 %	56.6 %	-39.9 pp
blocked_rate	model_family=claude	prompt_variant=path_margin	21	95.2 %	55.8 %	+39.4 pp
correct_rate	dataset_group=eight_scenarios_seed_v0	model_family=other	60	56.7 %	93.8 %	-37.2 pp
correct_rate	advanced_source=supplementary_reviewed	visual_condition=none	270	93.7 %	58.1 %	+35.6 pp

目标	条件 A	条件 B	样 本 数	联 合 率	截 断 加 性 期望	截 断 交 互 残差
unsupported_ assumption_r ate	dataset_group=supple ment_boundary_precisi on	clearance_margin_bin= margin_0cm	45	35.6 %	1.1%	+34.5 pp
unsupported_ assumption_r ate	dataset_group=supple ment_boundary_precisi on	boundary_reference_cla ss=zero_margin_border line	45	35.6 %	1.1%	+34.5 pp

二阶交互结果主要用于发现值得解释的组合。许多边界实验组合的正确率接近 100%，原始加性期望可能超过 100%，因此本表展示的是截断到 0-100% 后的期望和残差。这些项不应被简单解读为因果效应，而应说明某些条件组合相对于边际趋势表现出明显额外偏离。交互分析提供了一种系统筛查机制：后续如果扩展更多真实场景，可以用同样方法找出模型、模态、prompt 和场景属性之间的异常组合。

二阶交互残差不应被解释为强因果证据，而应被看作异常组合筛查工具。它的价值在于提醒我们：某些模型、模态、prompt 变体和实验条件同时出现时，结果可能比单独看两个条件的边际趋势更偏离预期。

17 各模型的认知边界定义

这里把模型认知边界定义为：在本空间任务中，模型从稳定正确判断转向过度保守、无依据假设或重复不稳定的输入条件集合。它至少包括四个维度：主实验正确率、主实验 blocked 率、净空裕量 pass 50% 交点、重复回答坍塌区间。

模型	主实验正 确率	主实验 blocked	补充实验 正确率	pass 50%交点 (cm)	坍塌裕量	边界定义
local_gemma4_12b_vision	46.7%	53.3%	未覆盖	未覆盖	无/未覆盖	local_gemma4_12b_vision 的边界数据不足， 需 要 结 合 主 实 验 解 释 。
local_gemma4_26b_a4b_text only	53.3%	26.7%	未覆盖	未覆盖	无/未覆盖	local_gemma4_26b_a4b_textonly 的边界数据不足， 需 要 结 合 主 实 验 解 释 。
local_gpt_oss_20b_textonly	20.0%	40.0%	未覆盖	未覆盖	无/未覆盖	local_gpt_oss_20b_textonly 的边界数据不足， 需 要 结 合 主 实 验 解 释 。

模型	主实验正确率	主实验 blocked	补充实验正确率	pass 50%交点 (cm)	坍塌裕量	边界定义
yunwu_chatgpt	6.7%	91.1%	46.5%	0.20	0.0	yunwu_chatgpt: pass 判断 50% 交点约为 0.20cm; 达到较稳定正确需要约 +2.0cm 正裕量; 重复回答不稳定区间: 0.0cm; 每增加 5% 环境细节, unsupported assumption 变化 - 0.2pp。
yunwu_claude	44.4%	48.9%	45.9%	4.25	2.0;5.0;10.0	yunwu_claude: pass 判断 50% 交点约为 4.25cm; 重复回答不稳定区间: 2.0;5.0;10.0cm; 每增加 5% 环境细节, unsupported assumption 变化 +3.4pp。
yunwu_doubao	22.2%	71.1%	71.7%	-1.00	无/未覆盖	yunwu_doubao: pass 判断 50% 交点约为 -1.00cm; 达到较稳定正确需要约 +2.0cm 正裕量; 每增加 5% 环境细节, unsupported assumption 变化 +2.3pp。
yunwu_gemini	6.7%	93.3%	32.7%	1.12	无/未覆盖	yunwu_gemini: pass 判断 50% 交点约为 1.12cm; 达到较稳定正确需要约 +2.0cm 正裕量; 每增加 5% 环境细节, unsupported assumption 变化 - 1.1pp。
yunwu_qwen	31.1%	60.0%	56.0%	0.20	0.0	yunwu_qwen: pass 判断 50% 交点约为 0.20cm; 达到较稳定正确需要约 +2.0cm 正裕量; 重复回答不稳定区间: 0.0cm; 每增加 5% 环境细节, unsupported assumption 变化 +4.6pp。

从使用角度看，ChatGPT 和 Gemini 在原始照片条件下要特别谨慎，因为它们在主实验中极易 blocked。Claude 的完整题面解释能力相对较强，但厘米级边界上偏保守。Doubao 在补充边界中较灵活，不过真实照片和复杂描述下仍可能误判。Qwen 的边界交点较低，但对环境描述噪声的 unsupported assumption 上升更明显。

图 20 展示每个模型的错误样本中，各类失效模式所占比例。unsupported assumption 高，说明模型常把未给出的障碍封闭性当成事实；calculation_error 高，说明模型主要在数值推理中出错；over_refusal 或 blocked 相关错误高，则说明模型更偏安全保守。由此，模型评估不再只是正确率比较，而是可以给出更细的认知边界画像。




图 20 失效模式挖掘热力图。该图展示不同模型的典型错误盲区。

18 主要结论与数据挖掘证据来源对照

下面把主要结论、支撑这些结论的数据挖掘方法、对应图表和关键统计量集中列出。可以看到，本研究的结论不是人工挑选个案后归纳出来的，而是由描述性统计、关联规则、Cramér's V、决策树、配对消融、bootstrap、边界曲线、多变量预测、聚类 and 失效模式挖掘共同支撑。综合第 7 到第 16 章，描述性统计先发现总体过度保守和 L2S 优势；关联规则、Cramér's V 和决策树说明这些现象与描述层级、扰动类型、失败模式稳定相关；图片消融和视觉显著性控制把 blocked 偏移定位到真实照片中的显眼障碍；尺寸补充和噪声梯度排除了“只是尺寸不够”或“只是文字太长”的简单解释；净空边界实验把认知边界量化到厘米级；最后，逻辑回归、置换重要性、PCA 聚类、雷达图和热力图又从多变量角度验证了这些发现。正因为多种方法指向同一组机制，本研究才能把模型评估从单纯正确率扩展为认知边界画像。

主要结论	支撑方法	报告图表 / 结果文件	证据
模型总体过度保守	描述性统计；判断分布；失效模式统计	图 7、图 8；主实验统计表； failure_mode_counts.csv	主实验 blocked 率为 67.4%，说明多数错误不是随机波动，而是稳定偏向不可通过。

L2S 是最有效的描述方式，空间关系组织比尺寸堆叠更重要	描述性统计；关联规则；Cramér's V；浅层决策树	图 7、图 9、图 10； decision_tree_is_correct.txt	L2S 正确率最高； level=L2S AND perturbation_type=none -> correct 的 confidence=83.3%、 lift=3.31；决策树也优先使用描述层级和扰动变量分裂。
原始照片显著增加 blocked 判断	图片消融；McNemar 检验；聚类 bootstrap	图 11；image_ablation_summary.md	有图 blocked 率 72.9%， 无图 blocked 率 38.2%， 差异 -34.7 pp；blocked 率区间不跨 0。
补充管道和消防栓尺寸没有显著提高正确率	尺寸补充效应；单元层面对比；多重检验 q 值	图 12；dimension_effect 相关结果	正确率从 15.0% 到 16.7%，只提高 +1.7 pp， q=0.8256；空间建模深度略升，但正确性未稳定改善。
无关文字环境描述不是主要干扰源	噪声梯度；线性斜率；配对 bootstrap	图 13；noise_paired_effects_vs_0.csv； noise_slope_by_model.csv	20% 相对 0% 时，正确率变化 +4.0 pp，95% CI [-8.0 pp, +16.0 pp]；区间跨 0。
模型认知边界可以量化到厘米级	净空裕量边界曲线；pass50 阈值；逻辑坍塌识别	图 14； cognitive_boundary_by_model.csv； logical_collapse_by_condition.csv	不同模型 pass50 交点不同，例如 Claude 约 4.25 cm，更保守；边界附近还会出现重复回答分裂。
真实楼梯题触发了特定失败机制，不是模	外部泛化对照；跨任务正确率比较	图 16；external_generalization 相关结果	ChatGPT、Gemini 在八场景题中正确率很高，但在老师真实题中很低，说明真实

型完全不会空问题			照片、局部障碍和运动约束共同造成困难。
实验变量可以被算法自动识别为重要因素	正则化逻辑回归；原始变量置换重要性	predictive_model_scores.csv ; predictive_raw_feature_permutation_importance.csv	5 折交叉验证 balanced accuracy=0.804 , ROC-AUC=0.868 ; level 、 dataset_group 、 analysis_tier 、 input_modality 、 prompt_variant 排在置换重要性前列。
模型不是简单好坏排序，而是有不同错误风格	模型行为指纹；PCA；K-Means 聚类；雷达图；失效模式热力图	图 17、图 18、图 19、图 20	Gemini 更高度保守，Qwen 判断熵更高，Claude 边界上偏保守；这些差异共同构成模型认知边界画像。

19 实验意义

这项工作的意义可以分成三层。课程层面上，它展示了一个比较完整的数据挖掘流程：从真实问题出发，构造实验矩阵，采集模型回复，自动标注再人工复核，最后用统计和模式挖掘找规律，而不是只挑几个例子讲故事。

AI 使用层面上，它说明用户不能把解释详细直接等同于判断可靠。在空间任务里，模型可能用公式、坐标、路径这些词包装错误推理。更好的做法是把问题拆成关键约束，让模型明确区分已知尺寸、未知假设、局部障碍和全局通行条件，同时对 final judgment 做人工复核。

社会价值层面上，轮椅通行关系到残疾人、老年人和行动不便者的实际生活。AI 如果被用于无障碍环境评估，就必须暴露自己的局限。在楼梯间、走廊或转角平台中，一个错误判断可能影响一个人是否敢走某条路线、是否需要绕行、是否需要他人协助。因此，这个项目不只是测试模型，也是在思考如何让 AI 更负责地参与公共空间和无障碍环境判断。

20 面向实际使用的建议

基于本项目结果，如果以后要用 AI 辅助判断类似空间通行问题，可以采用以下原则。

不要只发照片。照片会提供现场信息，但也可能强化显著障碍物干扰。

不要只堆尺寸。尺寸需要被组织成关键净空、通行路径和运动约束。

要求模型列出已知事实和额外假设。如果模型假设某个障碍物封死通道，应要求它指出依据。

对边界条件保持保守。净空接近轮椅宽度时，应由人工或几何工具复核。

使用多轮交叉检查。可以分别让模型在有图、无图、路径分解、尺寸表格条件下回答，看结论是否稳定。

对无障碍和安全相关问题，不应把 AI 作为最终裁决者。AI 更适合做信息整理和风险提示。

21 局限性 with 后续工作

本研究还有局限。第一，自动标注经过复核后，仍可能有少量边界样本存在争议。第二，部分用到的本地模型样本量较小，不能和云端模型完全等量比较。第三，净空边界实验主要通过文字改变尺寸，还没有为每个裕量生成严格比例的图像。

后续可以继续做三件事。第一，收集更多真实楼梯间、走廊、门厅、转角、电梯厅等无障碍场景，建立真实空间通行数据集。第二，引入 CAD 或几何仿真，把 AI 回复与可计算几何算法对照。第三，设计更细的视觉显著性实验，比如改变障碍物颜色、大小、位置和遮挡程度，进一步分析多模态模型如何分配视觉注意力。

22 复现路径与代码说明

本项目主要文件和脚本如下。

文件或脚本	作用
data/prompt_matrix_seed.csv	主实验 prompt 矩阵。
data/prompt_matrix_supplement_noise_sensitivity_clean.csv	无关环境描述梯度 prompt。
data/prompt_matrix_supplement_cognitive_boundary.csv	净空裕量边界 prompt。
data/prompt_matrix_supplement_visual_salience.csv	视觉显著性控制 prompt。
src/collect_responses.py	调用模型 API 或采集回复。
src/prepare_annotation.py	把原始回复整理成待标注表。
src/auto_annotate.py	调用强模型进行机器标注。

文件或脚本	作用
src/mine_patterns.py	关联规则、卡方、Cramér's V、决策树等数据挖掘。
src/advanced_mining.py	跨数据集正则化逻辑回归、置换重要性、模型行为指纹、PCA 聚类 and 二阶交互效应。
src/analyze_image_ablation.py	图片消融配对分析。
src/analyze_dimension_effect.py	尺寸补充效应分析。
src/analyze_supplementary_experiments.py	噪声、边界、视觉显著性补充实验分析。
src/build_requirement_audit_figures.py	生成认知边界热力图、模型对比雷达图和失效模式热力图。

复现主要分析可运行：

```
python src/mine_patterns.py --input
data/processed/reviewed/annotated_responses_teacher_newdims_merged_reviewed.csv --out
outputs_teacher_newdims_mining_reviewed_final
python src/analyze_image_ablation.py --input
data/processed/reviewed/analysis_ready/teacher_image_ablation_reviewed.csv --out
outputs_teacher_newdims_image_ablation_reviewed
python src/analyze_dimension_effect.py --input
data/processed/reviewed/analysis_ready/teacher_dimension_comparison_reviewed.csv --out
outputs_teacher_dimension_effect_reviewed
python src/analyze_supplementary_experiments.py --input
data/processed/annotated_responses_supplementary_reviewed.csv --out
outputs_supplementary_experiments_reviewed
python src/advanced_mining.py --out outputs_advanced_mining
```

23 结论

这项研究从真实轮椅转弯问题出发，做了一个围绕空间建模认知边界的数据挖掘项目。最终结论有六点。第一，模型在真实楼梯转角题中总体过度保守，主实验 blocked 率为 67.4%。第二，L2S 这种路径清楚但不过度形式化的描述最稳定，说明空间关系组织比尺寸堆叠更重要。第三，图片消融证明原始照片显著提高 blocked 率，视觉输入在本任务中不是单纯增益。第四，补充管道和消防栓尺寸没有显著提高正确率，核心错误不是信息缺失，而是局部障碍和可通行路径的建模失败。第五，净空裕量实验把模型认知边界量化到厘米级，不同模型的 pass 阈值和逻辑坍塌区间差异明显。第六，多种数据挖掘方法给出了相互印证的证据：关联规则、Cramér's V、决策树、正则化逻辑回归和置换重要性共同显示，影响正确性的核心不是回答长度本身，而是描述层级、prompt 组织方式、输入模态和实验条件；PCA 聚类、雷达图和失效模式热力图进一步表明，不同模型不是简单好坏排序，而是具有不同的错误风格和认知边界。

所以，我们对这个项目的最后判断是：当前 AI 可以作为空间问题的辅助分析工具，但在轮椅通行这种真实、局部、带安全后果的问题上，它仍需要结构化提示、几何复核和人工判断共同约束。可靠的 AI 使用方式不是迷信回答，而是知道模型会在哪些边界上失效。

参考文献

1. Mohammad Asadi, Jack W. O'Sullivan, Fang Cao, Tahoura Nedaei, Kamyar Fardi, Fei-Fei Li, Ehsan Adeli, Euan Ashley. Mirage: The Illusion of Visual Understanding. arXiv:2603.21687v2, 2026.
2. Rakesh Agrawal, Tomasz Imielinski, Arun Swami. Mining association rules between sets of items in large databases. Proceedings of the 1993 ACM SIGMOD International Conference on Management of Data, 1993.
3. Leo Breiman, Jerome Friedman, Richard Olshen, Charles Stone. Classification and Regression Trees. Wadsworth, 1984.
4. Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika, 1947.
5. Harald Cramér. Mathematical Methods of Statistics. Princeton University Press, 1946.